

프로젝트 #2 발표평가

<RGB-D Transformer 기반 객체 탐지를 이용한 포트홀 인식 정밀도 개선>

[6조] 전창수(팀장), 강태현, 이경재

rnd@wooyoungmed.com, spprou@naver.com, kung1215@cbnu.ac.kr

충북대학교 산업인공지능연구센터

CONTENTS

I

프로젝트 #2 개요

프로젝트 개요 및 선정 논문 소개, 팀 구성원 소개 및 업무분장

II

서론 (Introduction)

연구 배경, 연구 필요성, 문제 정의

III

방법 및 구현 (Methodology & Implementation)

문제 해결을 위한 방법론

IV

실험 구성 및 평가 방법 (Experiment Settings)

데이터셋, 하이퍼파라미터, 컴퓨팅 환경, 평가지표

V

결과 및 분석 (Results & Analysis)

학습 결과, 정확도, 혼동행렬, 비교 평가, 결과 분석

CONTENTS



한계점 및 토론 (Limitations & Discussions)

본 연구의 한계점 및 개선점 등 논의



결론 및 향후 연구

본 연구의 결론 및 향후 연구 등 논의

■ 프로젝트 목표

RGB-D Transformer 기반 객체 탐지를 이용한 포트홀 인식 정밀도 개선

■ 프로젝트 배경 및 필요성


1) 프로젝트 배경

- 도로 기반 인프라 관리에서 포트홀 탐지는交通安全 및 유지관리 비용 측면에서 매우 중요한 과제로 인식되고 있음 [1]
- 최근에는 차량에 부착된 카메라 기반의 영상 인식 기술을 활용한 비전 기반 포트홀 탐지가 주목받고 있으며, 특히 딥러닝 기반 객체 탐지 알고리즘(YOLO 등)이 실시간 측면에서 적극적으로 연구되고 있음

2) 프로젝트 필요성

- 기존 RGB-Only 객체 탐지 기술은 명암/조도/질감이 유사한 환경에서 포트홀을 배경과 구분하지 못하는 한계가 있음 [2]
따라서 객체의 형태뿐 아니라 깊이(Depth) 정보와 공간적 위치 차이를 반영한 인식 구조의 도입이 필요함
- 기존 CNN 기반 탐지 모델은 지역적인 특징 중심 학습에 치우쳐 있어 전역적 관계 파악 능력이 부족해 물리적으로 떨어져 있는 도로 요소 간의 구조적 관계를 인식할 수 있는 Transformer 기반 인코더의 도입이 요구됨 [3]

■ 포트홀 사전 보수체계 필요



국민권익위원회 민원정보분석과의 2024년 4월 “포트홀(도로파임) 관련 민원 분석”에 따르면 2022년 1월부터 2024년 4월까지 민원분석시스템에 수집된 포트홀 관련 민원은 총 5만 2,262건



(출처 : <https://m.news.nate.com/view/20240307n08249>)

최신 시스템 활용

포트홀은 시간이 지날수록 심화되어 사고의 위험성이 급격히 늘어나므로, 최신 시스템(AI)을 이용해 선제적으로 탐지·보수가 필요

유지보수 필요

시스템을 통해 수집한 포트홀 이력을 활용해 반발구역을 확인하고 집중발생 시기 순찰강화를 통해 신속한 도로파임 탐지 및 보수 필요

■ 포트홀 탐지 정확도 한계

실제 도로 환경에서 포트홀을 검출할 때는 하단그림과 같이 관측 조건에 따라 난이도가 크게 달라짐. 하단 이미지의 좌측처럼 가까이에서 촬영된 포트홀은 형태와 경계가 뚜렷하여 비교적 쉽게 식별되지만, 하단 이미지의 우측 대시캠 시야 영상에서는 멀리 보이는 작은 포트홀이 노면과 구별하기 어려워 검출이 누락될 가능성이 있음. 또한 비슷한 색상의 패치나 도로 보수 자국이 포트홀로 오인되거나, 빛 반사로 인한 하이라이트 영역이 잘 못 탐지되는 등 오탐지 사례도 발생.



〈사진〉 좌측 이미지의 포트홀은 식별이 쉽지만, 우측 이미지의 포트홀은 식별이 제한됨

■ 문제정의 및 주요 기여점



문제 1. RGB 영상만으로는 포트홀과 배경 구분이 어려움

- 아스팔트의 어두운 색상과 포트홀의 질감이 유사하여, 조명/그림자/노면 반사 등 다양한 조건에서 탐지 실패율이 높음
- 기존 YOLO 모델은 명암 중심의 특징만 추출하므로 깊이 정보 반영이 불가



문제 2. 기존 CNN 기반 탐지 모델은 전역 구조 파악에 한계

- CNN은 지역적인 특징 추출에 강점이 있으나, 포트홀과 주변 노면, 페인트 흔적, 물자국 등 복합적 구조 인식에는 한계
- 포트홀 주변 문맥 정보까지 함께 이해하지 못함



주요 기여 1. RGB-D 입력을 통한 공간 인식 정보 보강

- 스테레오 카메라와 MiDas 기반으로 Depth Map을 생성
- RGB + Depth 4채널 입력을 YOLO 구조에 맞게 확장하여, 공간 시차 기반의 객체 인식 성능을 유도



주요기여 2. Transformer Block을 통한 전역 관계 학습 도입

- YOLOv8 백본에서 추출된 Feature Map에 Transformer Block 삽입
- Self-Attention 기반으로 장면 내 위치 간 관계 및 거리 기반 특징을 함께 학습
- Depth-Aware Attention을 적용하여 거리 기반 주의 집중 강화

■ 모델 구조


본 프로젝트에서는 RGB-D 형태의 4채널 영상을 입력으로 하여 YOLOv8 기반의 객체 탐지 모델을 설계함.

입력은 RGB(3채널) + Depth(1채널)로 구성되며, YOLOv8의 입력 계층을 수정해 이를 수용하도록 조정함.

백본 네트워크에서 추출된 중간 Feature Map은 Transforemr Block으로 전달되며, 여기서 Depth-Aware Self-Attention을 통해 포트홀과 주변 환경 간의 공간적 관계 및 깊이 기반 시차 정보를 학습함.

Transformer는 각 위치간의 단순 유사성뿐 아니라, 깊이 차이에 따른 상대적 중요도를 동적으로 반영할 수 있는 구조로, 포트홀과 그림자, 페인트 흔적 등 시각적으로 유사하지만 의미가 다른 객체들을 효과적으로 구분하는데 핵심적인 역할을 수행함.

Transformer는 단일 픽셀 단위의 특징을 넘어서, 포트홀과 주변 구조간의 전역적 관계 및 깊이 기반 문맥 정보까지 통합적으로 학습할 수 있도록 지원.



〈그림〉 구현 모델의 구조

본 모델의 Transformer Block은 단일 모달 구조를 유지하면서도, Feature Map 내 Depth 차이에 따른 positional bias를 attention 연산에 반영하여, Depth-aware 인식 성능을 향상시킴

■ 모델 구현 방법

YOLOv8 구조 수정

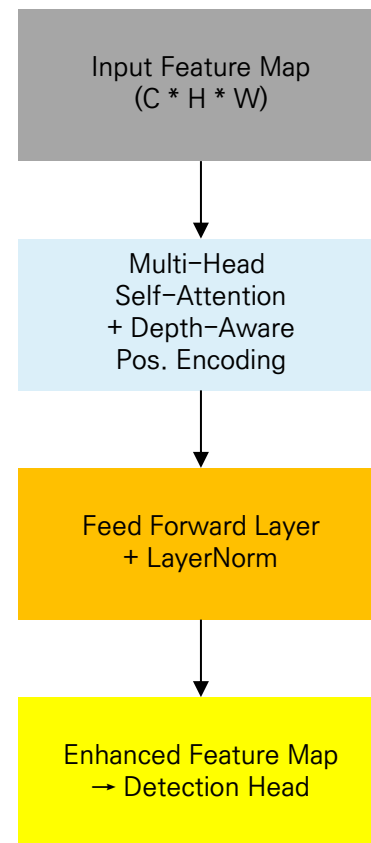
- 입력 채널 확장 : 기존 RGB(3채널) → 수정 RGB + Depth (4채널)
- 초기 Conv layer 변경 : Depth 정보 수용 가능하도록 설정
- COCO 기반 가중치(pretrained weight)활용을 위해 나머지 구조는 동일하게 유지

Transformer Block 결합

- YOLOv8 백본에서 추출된 Feature Map을 입력으로 사용
- Transformer 구성 요소:
 - ◆ Multi-Head Self-Attention (MHSA)
 - ◆ Depth-Aware Positional Encoding
 - ◆ Feedforward Layer + LayerNorm
- Transformer 출력 → Detection Head로 전달 → Bounding box 예측

Depth-Aware Attention

- Depth map의 거리 차이를 Attention Score 계산에 반영
- 유사한 시각적 패턴(그림자, 얼룩 등)과 실제 포트홀을 구분
- 공간적 관계 및 거리 기반 인식 능력 향상



■ 실험 구성

데이터셋 구성

- RGB 이미지 : 5,700장 (도로 포트홀 중심)
- Depth Map : MiDas (DPT-Hybrid) 모델로 RGB → Depth 변환
- 라벨 형식 : YOLO 형식 : class x_center y_center width height
- 데이터 분할 : train : val : test = 7 : 2 : 1

모델 구조

- YOLOv8 백본 구조 기반
- 입력 Conv : Conv(4, 32, 3, 1, 1)으로 수정 (RGBD 입력 지원)
- Transformer Block 삽입
 - Depth-Aware Attention (Multi-head + Positional Encoding)
 - YOLO Head 이전 feature map에 적용

항목	값
Epoch	100
Batch Size	16
Optimizer	AdamW
Learning Rate	1e-4
LR Scheduler	Cosine Annealing + Warmup
입력 크기	416*416
초기 가중치	COCO Pretrained (yolov8n.pt) 활용, strict=False로 로딩

■ 평가 방법

정량적 평가지표

- mAP@0.5 (Mean Average Precision) : IoU ≥ 0.5 기준으로 예측과 실제 라벨의 정합률을 평균하여 모델의 전반적인 탐지 성능을 수치화함.
- Precision (정밀도) : 탐지한 포트홀 중 실제 포트홀일 확률. 오탐 (false positive) 방지 성능을 측정

정성적 평가지표

- 탐지 시각화 (bounding box overlay) : 예측 결과를 실제 이미지 위에 표시해 포트홀 정확 탐지 여부를 육안으로 확인
- RGB-only vs RGBD 비교 : Depth 정보가 탐지 성능에 어떻게 기여했는지 시각적으로 비교 분석
- 혼동 요소 구분력 : 그림자, 얼룩, 타이어 자국 등 유사 시각 요소와의 구분 능력 확인

■ 모델 분석 결과 요약


	입력	mAP@0.5	Precision	Recall	특징
YOLOv8 (baseline)	RGB	74.6%	76.1%	72.4%	기존 구조, RGB만 입력
YOLOv8 + Depth	RGB + Depth	78.3%	79.5%	76.9%	단일 Depth 채널 추가
YOLOv8 + Depth +Transformer	RGB + Depth	82.1%	83.8%	81.4%	관계 인식 가화, 성능 향상

Transformer + Depth 입력 구조는 포트홀 탐지 정확도를 평균 7% 이상 향상시킴

■ 모델 결과 정성적 평가 비교

이미지	RGB-Only 결과	RGBD+Transformer 결과
어두운 도로 + 그림자	포트홀 미탐	정확 탐지
물자국 있는 장면	오탐 발생	정상 탐지
작은 포트홀	탐지 실패	탐지 성공

- Depth를 통한 표면 높낮이 인식 덕분에 시각적 유사 요소 (물자국, 얼룩 등)와의 구분 능력이 향상됨
- Transformer의 전역적 관계 인식 덕분에 포트홀 경계와 주변 구조 구분이 강화됨
- RGB only 구조는 저조도 환경, 복잡한 배경에서 탐지 성능 급감



■ 한계점 및 토론



Depth 맵의 품질

- 1 MiDaS 기반 추론은 상대 깊이 이므로, 실제 거리 정밀도는 제한적
→ ZED 카메라 등 실측 Depth로 모델 성능 재검증

추론시간 저하

- 2 Transformer BLock 도입 시 추론 속도(FPS)가 약간 증가함 (약 10~15FPS)
→ Swin-Tiny, MobileViT 등으로 연산량 감소

데이터 편중

- 3 포트홀 크기/형태 다양성 부족으로 일반화 성능 한계 가능성
→ 다양한 조도/환경 조건 반영한 RGBD 증강 강화

■ 향후 연구 방향

1

실측 Depth 데이터 기반 모델 재학습

- MiDaS가 아닌 실제 센서(ZED 등) 기반 Depth로
정밀도 향상 검증

2

다중 Transformer 계층 실험

- 관계 표현력 강화를 위한 다중 Transformer 삽입
구조 실험

3

포트홀 분할 (Segmentation) 확장

- 탐지 → 영역 분할로 전환하여 정밀한 손상 면적
추정 가능성 모색

4

다중 시점 학습 (Multi-view learning)

- 시간/공간적 프레임 흐름 기반 포트홀 발생 예측
확장 가능성 탐색

- 연구 목표: 수술 후 통증 관리를 위해 사용되는 PCA(Patient-Controlled Analgesia) 시스템의 사용 데이터를 기반으로, 오심 및 구토(PONV)의 발생 요인을 분석하고 예측 모델을 구축
Establishing a Personalized Pain Management Strategy Based on PCA Bolus Attempts and PONV Prediction

■ 연구 배경 및 필요성

- 수술 후 통증 관리는 환자의 회복 속도와 직결되며, 환자 자가통증조절(PCA)은 널리 사용되는 방식이다. 그러나 PCA 사용 중 오심 및 구토(PONV)는 대표적인 부작용으로, 발생 시 환자의 불편뿐 아니라 추가 약물 투여, 입원 기간 연장, 만족도 저하 등의 문제를 야기한다.
- 기존 연구에서는 성별(여성), 연령(젊은층), 마취 종류 등이 PONV 발생에 영향을 준다고 알려져 있으나, 이를 실질적인 데이터 기반 분석과 예측 모델로 발전시킨 사례는 제한적이다. 또한 PCA 사용의 정량적 기록(볼루스 시도량, 사용 시간대 등)은 효과적인 통증 관리 전략 수립에 활용될 수 있는 중요한 지표임에도 불구하고, 이에 대한 종합적 분석은 부족한 실정이다.
- 이에 따라 본 연구는 다변량 데이터 기반으로 PONV 예측 정확도를 높이고, 데이터 기반 맞춤형 통증 관리의 가능성을 제시하여 회복 기간 단축 및 환자 만족도 향상하는 데 그 필요성이 있다.

■ 연구계획

계획	일정						산출물
	7월	8월	9월	10월	11월	12월	
데이터 수집 및 전처리							<ul style="list-style-type: none"> - 2023년 병원 EMR 기반 환자 1,270명 자료 확보 - 결측치 보완, BMI 계산, 범주형 인코딩 등
기초 통계 및 시각화 분석							<ul style="list-style-type: none"> - 연령별/성별/수술과별 PONV 및 볼루스 시도량 비교 - 상관관계 및 시계열 분석
머신러닝 모델 구축							<ul style="list-style-type: none"> - PONV 분류 모델(RandomForest, LogisticRegression 등) - NRS 회귀 모델(RandomForestRegressor 등) - 성능평가 (정확도, 정밀도, F1 등)
고위험군 군집 분석 및 맞춤 전략 제안							<ul style="list-style-type: none"> - 고령자/여성 등 주요 군집 도출 - 사용 시간대 및 시도량 기반 통증 유형 분류
논문 작성 및 시각화 자료 정리							<ul style="list-style-type: none"> - 주요 결과 정리 및 그래프 삽입 - 표지, 요약문, 참고문헌 정리

■ 연구 목표:

딥러닝을 활용한 이차전지 분리막의 외관 검사 시스템
Visual Inspection System of Secondary Battery Separator Using Deep Learning

■ 연구 배경 및 필요성

- 최근 전기차 업계에서 잇단 화재가 발생하며 배터리 안전이 대두되고 있음. 이에 따라 배터리 안전에 직접적인 역할을 하는 배터리분리막은 전기차 화재 예방에 있어 절대적으로 중요한 소재임. 따라서 각 배터리 분리막 제조사에서 품질관리를 사내 핵심가치로 여기며 안전과 함께 중점관리로 다루고 있음.
- 한편, AI의 급속한 발전과 제조업체의 점진적인 스마트팩토리 전환으로, 제조업계의 생산 및 품질공정은 AI를 통한 자동화생산으로 점차 전환되어 가고 있다. 따라서 생산성 증가 및 인건비 절감, 품질신뢰도 상승을 위해서 배터리 분리막 업계 역시 AI와 자동화생산을 도입하지 않을 수 없음.
- 그러나 배터리 분리막 품질검사의 경우, 자동화 검사기기로 검출이 어려운 불량률이 다수이기에 자동화 검사기기가 아닌 사람이 직접 관능검사로 검사하고 있음. 또한 제품당 20가지 이상의 많은 양의 검사를 시행해야 하기 때문에 품질검사원에게는 높은 숙련도와 함께 정확하고 빠른 업무처리능력이 요구되고 있는 실정임. 거기에 신입사원 입사 시, 신입사원 교육 및 멘토링까지 해야하기 때문에 숙련된 품질검사원의 업무부담감은 매우 높은 상황이며 이로 인하여 생산성 하락과 추가인건비 발생, 품질검사 신뢰도 하락 등의 다양한 문제가 발생되고 있음.
- 이와같은 현업의 문제점을 해결하고자, 가장 많이 발생하는 대표적인 품질 불량 2~3가지를 숙련자 수준으로 검출할 수 있는 딥러닝 기반의 자동화검사기기를 개발 및 현장 배치하여, 신입사원이 숙련되는 기간동안 발생하는 Loss를 최소화 또는 상쇄하여 생산성 향상과 인건비 절감, 품질검사 신뢰도 상승 등의 효과를 기대하는 것이 본 프로젝트의 주요 목표임.

■ 연구 계획

계획	일정						산출물
	7월	8월	9월	10월	11월	12월	
실험환경 구축 및 대상불량 선정							<ul style="list-style-type: none"> 대표 불량 유형 3종 선정 (예: 핀홀, 눌림자국, 스크래치) 카메라, 조명, 촬영 환경 구축 YOLO 학습 환경 세팅 (PyTorch, CUDA, YOLOv8)
데이터 수집 및 전처리							<ul style="list-style-type: none"> 불량 및 정상 샘플 촬영 (유형별 최소 100장 목표) 어노테이션 작업 (Roboflow 등 활용) 데이터 증강 (밝기, 회전, blur 등) YOLO 학습 및 베이스라인 모델 완성
실험1 : 모델 vs 인간 비교실험							<ul style="list-style-type: none"> 숙련자 vs 비숙련자 vs YOLO 모델로 동일 불량 샘플 평가 불량 검출률(Recall), 누락률(FN), 오탐률(FP) 측정 YOLO 성능 보완 필요 시 하이퍼파라미터 조정 및 재학습 불량 유형별 모델 강점/약점 정리
실험2 : 현장 시뮬레이션 및 보조 효과 분석							<ul style="list-style-type: none"> 비숙련자가 검사기 없이/검사기와 함께 검사한 결과 비교 실시간 추론 환경 구현 (OpenCV + YOLO or 간이 GUI) 업무 보조 효과 분석 (불량 검출률 개선, 오탐 감소 등) 현장 투입 가능성 및 한계 분석
데이터정리 및 논문 초안 작성							<ul style="list-style-type: none"> 실험 결과 시각화 (그래프, 표 등) 논문 구조 확정 및 초안작성 (서론-관련연구-방법-실험-결과-결론) 지도교수/가디언과의 상담을 통한 피드백 반영 및 수정
논문심사(발표) 및 지적사항 반영							<ul style="list-style-type: none"> 논문심사 시 지적된 사항 논문 반영
최종 완성 및 제출							<ul style="list-style-type: none"> 오탈자 수정, 인용 정리, 참고문헌 작성 최종본 작성 및 제출

■ 연구 목표:

구형 계량기 숫자 인식을 위한 딥러닝 기반 디지털 판독 및 서버 전송 시스템
Deep Learning-Based Digital Reading and Server Transmission System for Old Meter Number Recognition

■ 연구 배경 및 필요성

- 국내외 다수의 건물, 특히 오래된 주택이나 산업 시설은 여전히 아날로그 방식의 구형 계량기를 사용하고있음. 이러한 구형 계량기는 디지털 네트워크와의 연동이 불가능하여 자동 검침, 원격 관리 등의 최신 서비스 적용에 한계가 있음
- 디지털 계량기로의 교체가 이상적이지만, 노후된 건물 구조, 설치 공간의 제약, 전원 공급의 어려움, 비용 문제 등으로 인해 전면적인 교체가 쉽지않음. 특히 사회적 취약지역이나 소규모 다가구 주택에서는 현실적으로 신형 계량기 설치가 어려움
- 에너지 관리 및 스마트시티 구현을 위해 실시간 데이터 수집과 분석은 필수적임. 하지만 구형 계량기를 사용하는 가구에서는 수동 검침 방식에 의존할 수 밖에 없어 인력, 시간, 정확성 측면에서 큰 비효율이 발생함
- 이미지 촬영을 통한 수치 인식 기술(OCR)은 구형 계량기를 그대로 유지하면서도 데이터를 디지털화할 수 있는 실용적 대안임. 최근 딥러닝 기반의 OCR 기술이 발전함에 따라 계량기의 다양한 종류의 촬영환경에서도 높은 인식 정확도를 기대할 수 있음
- 에너지 절약 및 탄소 배출 감축을 위한 정책이 강화되면서, 정확하고 실시간 에너지 사용 모니터링이 더욱 중요해지고 있음. 이를 위해서는 구형 계량기를 사용하는 계층까지 포괄하는 광범위한 계량 데이터 수집이 가능해야함

■ 연구 계획

계획	일정						산출물
	7월	8월	9월	10월	11월	12월	
사전 조사 및 요구사항 분석							<ul style="list-style-type: none"> 문헌조사 보고서 요구사항 명세서
데이터 수집 및 전처리							<ul style="list-style-type: none"> 계량기 이미지 데이터셋 Label 데이터
딥러닝 모델 설계 및 학습							<ul style="list-style-type: none"> OCR 모델 코드 학습 로그 정확도 보고서
모델 평가 및 성능 개선							<ul style="list-style-type: none"> 개선 모델 결과 혼동 행렬 성능 비교표
서버 연동 및 시스템 통합 개발							<ul style="list-style-type: none"> 서버 통신 모듈 통합 시스템 시연 영상
현장 테스트 및 보완 작업							<ul style="list-style-type: none"> 테스트 보고서 오류 수정 로그
최종 완성 및 제출							<ul style="list-style-type: none"> 최종 보고서 발표자료(PPT) 시스템 결과물

- [1] Safyari et al., Pothole Detection Methods Using Vision-based Techniques: A Review, Automation in Construction
- [2] Mathivanan et al., A Deep Learning-Based Method for Pothole Detection Using RGB Images, IEEE Access, 2023
- [3] Savrasovs, M., & Principal, N. (2024). Analysis of Pothole Detection Accuracy of Selected Models. Transport and Telecommunication Journal, 25(1), 16.
- [4] 국민권익위원회. (2024). 국민이 안심하는 생활안전 확보를 위한 포트홀(도로파임) 관련 민원 분석. 국민권익위원회 민원정보분석과.
- [5] MBN. (2024). 운전자 위협하는 포트홀 탐지...AI 활용해 사고 줄인다. MBN News.
- [6] Ling, M., Shi, Q., Zhao, X., Chen, W., Wei, W., Xiao, K., ... & Zeng, Y. (2024). Nighttime Pothole Detection: A Benchmark. Electronics, 13(19), 3790. [5] Safyari, Y., Mahdianpari, M., & Shiri, H. (2024). A Review of Vision-Based Pothole Detection Methods Using Computer Vision and Machine Learning. Sensors, 24(17), 5652.

감사합니다

Q&A

